

MultiSpec-GeoDiff

Stage-I Feasibility Loop

多模态谱图驱动的几何分子结构反演 | Demo 说明

谢翔宇 中国科学技术大学 xxy220348@mail.ustc.edu.cn

项目名称	MultiSpec-GeoDiff: Multimodal Spectra-Driven Geometric Molecular Structure Inversion
提交类型	DP Technology 实习项目 Demo
当前阶段	Stage-I 可行性闭环
实验数据	200 条 NIST 实验 IR 光谱
仓库地址	https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo
一键运行	<pre>git clone https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo.git && cd MultiSpec-GeoDiff-Demo && pip install -r 03_code/requirements.txt && python 03_code/run_demo.py --query_id 0 --data 04_data/IR_nist_200.jsonl --top_k 5</pre>
测试命令	<pre>PYTHONPATH=03_code/src pytest 03_code/tests -q</pre>
验证状态	22 个测试通过 GitHub Actions CI 通过

1 任务目标、定位与价值

分子光谱到结构的反演是 AI for Science 领域典型的逆问题。实验红外光谱存在噪声、稀疏性和一谱多解的内在歧义，直接生成 SMILES 字符串忽视了分子的图拓扑与三维几何结构。本项目提议将反演形式化为多阶段条件生成问题；本 Demo 聚焦于 **Stage-I 最小可行性闭环**。

核心管线为：

实验 IR 光谱 → 坐标感知谱图编码 → 候选检索 → 前向谱图重排 → Top-K 候选分子

定位说明：本 Demo 不是训练完备的生成模型，也不是生产级未知物鉴定系统。它展示的是一个可追溯的 AI-for-Science 工作流——在真实实验数据上验证“候选提出 + 前向一致性校验”的闭环思想，符合实习项目对可行性、逻辑推理与创新性展示的要求。

Current implementation validates the Stage-I single-modality IR loop. Multimodal fusion, graph diffusion, pairwise-distance prediction, and TFN/SE(3)-equivariant refinement are planned extensions, not completed components.

2 已完成核心能力

200 条 NIST 实验 IR 光谱用于 Demo 级可行性验证，未用于训练完整生成模型。

能力模块	当前 Demo 状态	仓库证明材料
NIST IR 数据加载	已实现	04_data/IR_nist_200.jsonl
谱图插值与归一化	已实现	spectra_preprocess.py
坐标感知谱图编码	已实现	spectra_encoder.py
谱图距离偏置注意力	已实现	spectral_attention.py, 热图
候选分子检索	已实现	candidate_generator.py
前向谱图重排	已实现	reranker.py
Top-K 输出与可视化	已实现	CSV, PNG 输出文件
可追溯 Demo 日志	已实现	trace_log.json
本地测试与 CI	已实现	22 测试, GitHub Actions
Pairwise 距离预测头	接口原型	distance_head.py
TFN/SE(3) 等变模块	接口原型	tfn_transformer_stub.py

3 Demo 工作流与输出示例

Demo 接受一条查询 IR 光谱，与包含 199 个分子的 NIST IR 候选库逐一比对，通过余弦相似度召回初始 Top-M 候选集，再由三项谱图一致性指标（余弦相似度、L1 距离和峰匹配）进行重排，最终输出 Top-K 候选分子及其分子结构图、查询与候选光谱叠加图、坐标感知注意力热图和可机读的 trace log。本工作流在可复现条件下验证 Stage-I 可行性闭环，并非生产级未知物鉴定系统。

3.1 输入与输出

	输入	输出
数据	04_data/IR_nist_200.jsonl	05_outputs/topk_candidates.csv
	每条含 SMILES / 波数 / 强度	05_outputs/spectrum_overlay.png
		05_outputs/molecule_grid.png
		05_outputs/attention_heatmap.png
		05_outputs/ablation_results.csv
		05_outputs/trace_log.json
参数	query_id = 0 top_k = 5	

3.2 输出示例

4 核心原理

4.1 坐标感知谱图编码

$$h_i = W_I \cdot I_i + p(\nu_i) \quad (1)$$

IR 光谱的每个数据点不是无结构的序列 token——它同时携带强度信息 I_i 与波数物理坐标 ν_i 。嵌入层将强度投影与傅里叶波数位置编码相加，使模型天然地感知每个点位于光谱的哪个位置。这是本 Demo 区别于普通 Transformer 序列编码的核心设计。




图 1: Stage-I Demo workflow。实心蓝色模块为已实现的 Stage-I 检索/重排闭环（200 条 NIST 实验 IR 光谱）；虚线模块为图扩散、pairwise 距离预测及 TFN/SE(3) 等变细化的未来接口，非本 Demo 已完成功能。

核心思路： IR 波数轴被视作物理坐标，而非无结构序列索引。

4.2 谱图距离偏置注意力

$$A_{ij} = \text{softmax}_j \left(\frac{Q_i K_j^T}{\sqrt{d}} + b(|\nu_i - \nu_j|) \right) \quad (2)$$

在 IR 光谱中，物理上邻近的波数区域具有更强的本征相关性——这一先验不应由模型从有限数据中从头学习。本设计在注意力中注入波数间距依赖的 RBF 偏置 $b(\Delta\nu) = \exp(-(\Delta\nu/\sigma)^2)$ ，使远离谱区之间的注意力权重被物理先验抑制。这与 Graph Transformer 中注入拓扑距离偏置的思路一致，但应用对象是**光谱物理坐标**。

核心思路： 注意力被物理谱距偏置，而非仅依赖 token 相似度。

4.3 候选检索与前向谱图重排

$$\text{Score}(G_k) = \lambda_1 \text{CosSim}(S_q, S_k) + \lambda_2 \text{PeakMatch}(S_q, S_k) \quad (3)$$

当前 Demo 使用检索而非训练完成的图扩散模型来产生候选——这是 Stage-I 的刻意简化。检索后，候选分子经前向谱图对比进行三指标重排（余弦相似度 + L1 距离 + 峰匹配），验证“候选提出 + 前向一致性校验”的闭环在真实实验数据上的可行性。在后续阶段，检索模块可替换为谱图条件图扩散生成。

核心思路： 候选分子通过前向谱图一致性进行重排，而非仅依赖嵌入相似度。




图 2: Demo 输出示例。(a) 查询光谱（黑色）与 Top-K 候选（彩色）叠加对比。(b) Top-K 候选分子二维结构及得分。(c) 谱图距离偏置注意力热图，对角线增强表明波数邻近区域具有更强局部相关性。

5 能力边界

当前 Demo 已实现：

- Stage-I IR 检索与重排可行性闭环（200 条 NIST 实验 IR 光谱）
- 坐标感知谱图编码（将波数轴视为物理坐标）
- 谱图距离偏置注意力（基于物理谱距而非 token 相似度）
- 候选分子检索与前向谱图重排
- 可视化输出（谱图叠加、分子网格、注意力热图）
- 可追溯执行日志（`trace_log.json`）
- 本地测试与 GitHub Actions CI（22 个测试全部通过）

当前 Demo 未包含：

- 未训练完整的图扩散生成模型
- 未训练完整的 pairwise 距离预测器
- 未训练完整的宇称分辨 TFN/SE(3)-Transformer
- 未接入 Raman、NMR、MS、UV 等额外模态（当前仅 IR 单模态）
- 未建立生产级未知物鉴定系统

这一边界是刻意的。Demo 的目标是展示核心思路与可行性闭环，而非交付完整的生产系统。Stage-II 和 Stage-III 的关键模块已作为可导入接口桩存在于代码库中，定义了清晰的接口签名与数据结构。

6 验证结果与价值

项目	状态
实验数据	200 条 NIST 实验 IR 光谱（04_data/IR_nist_200.jsonl）
Demo 命令	<code>python 03_code/run_demo.py --query_id 0 ... --top_k 5</code>
本地测试	22 个测试全部通过（pytest）
CI	GitHub Actions Tests 通过
关键输出	Top-K CSV、谱图叠加、分子网格、注意力热图、trace log
消融验证	流程各模块可独立开关和记录；Full pipeline 在余弦相似度之外引入 L1 与峰匹配信号

Demo 的核心价值可概括为三点：

1. 证明了真实实验 IR 光谱可以进入可复现的检索/重排闭环。
2. 证明了坐标感知谱图注意力是可实现的，并可作为后续阶段的编码器基础。
3. 为检索 → 图扩散 → 几何细化的逐步替换提供了清晰的代码接口。

消融说明：当前消融主要用于验证流程各模块可被独立开关和记录，非统计显著性能声明。由于样本规模仅 200，结果应理解为 Demo 级可行性检验。Full pipeline 在纯余弦相似度之外引入 L1 与峰匹配信号，使候选排序更接近谱图物理一致性。

7 后续演进路线

本 Demo 聚焦于 Stage-I 可行性验证；Stage-II 与 Stage-III 为计划中的未来扩展方向，当前代码库中保留接口定义但未包含完整训练的生成模型。

Development Roadmap and Scope Boundary




图 3: 开发路线图与能力边界。Stage-I 为本提交已完成内容；Stage-II 与 Stage-III 为计划中的未来扩展。当前 Demo 验证的是可行性闭环思想，而非完整训练的分子生成模型。

8 提交材料清单

材料	路径
GitHub 仓库	https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo
项目提议	01_project_proposal/proposal.md
Feishu 风格 Demo 说明	02_demo_document/DEMO 说明.md
Demo 说明 PDF	02_demo_document/demo_report.pdf (本文档)
LaTeX 源码	02_demo_document/latex/demo_report.tex
代码	03_code/ (核心模块 + 测试 + CLI 入口)
数据	04_data/IR_nist_200.jsonl (200 条 NIST IR 光谱)
输出	05_outputs/ (CSV, PNG, JSON)
Notebook	06_notebook/demo_pipeline.ipynb
CI	.github/workflows/tests.yml

主命令: `git clone https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo.git && cd MultiSpec-GeoDiff-Demo && pip install -r 03_code/requirements.txt && python 03_code/run_demo.py --query_id 0 --data 04_data/IR_nist_200.jsonl --top_k 5`

测试命令: `PYTHONPATH=03_code/src pytest 03_code/tests -q`

仓库地址: <https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo>