

MultiSpec-GeoDiff — Demo 说明

项目名称: MultiSpec-GeoDiff **提交类型:** DP Technology 实习项目 Demo **当前阶段:** Stage-I 可行性闭环 **数据:** 200 条 NIST 实验 IR 光谱 **主入口:** <https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo>

一键运行:

```
python 03_code/run_demo.py --query_id 0 --data 04_data/IR_nist_200.jsonl --top_k 5
```

1. 任务目标、定位与价值

本 Demo 对应提交的项目提议 “**MultiSpec-GeoDiff: 多模态谱图驱动的几何分子结构反演**” (详见 01_project_proposal/proposal.md)。

完整提议覆盖从多模态谱图编码、图扩散生成、pairwise 距离预测到 SE(3) 等变细化的端到端管线。本次提交聚焦于 **Stage-I 可行性闭环**:

实验 IR 光谱 → 坐标感知谱图编码 → 候选检索 → 前向谱图重排 → Top-K 候选分子

定位说明: 本 Demo 不是训练完备的生成模型，也不是生产级未知物鉴定系统。它展示的是一个**可追溯的 AI-for-Science workflow**: 在真实实验数据上验证” 候选提出 + 前向一致性校验” 的闭环思想。GitHub 仓库是主要提交入口，本 PDF 为 reviewer 提供配套说明。

2. 已完成核心能力

以下模块已在 Stage-I 中实现，均可通过命令行复现:

能力模块	当前实现	证明材料
NIST IR 数据加载	200 条实验光谱, 含 SMILES / 波数 / 强度	04_data/IR_nist_200.jsonl
谱图预处理	公共网格插值 (400–4000 cm ⁻¹ , 1800 点) + 归一化 + 峰提取	spectra_preprocess.py
坐标感知谱图编码	强度投影 + 傅里叶波数位置编码	spectra_encoder.py
谱图距离偏置注意力	自注意力注入 $b(\nu_i - \nu_j)$ RBF 偏置	spectral_attention.py + 热图

能力模块	当前实现	证明材料
候选分子检索	查询 vs 199 候选库余弦相似度检索	candidate_generator.py
前向谱图重排	余弦 + L1 + 峰匹配三信号加权重排	reranker.py
Top-K 输出	CSV 排序表 + 谱图叠加 + 分子结构 + 注意力热图	05_outputs/
可追溯性	完整执行元数据 JSON 日志	trace_log.json
验证	22 个测试 + GitHub Actions CI	.github/workflows/tests.yml

数据规模说明： 200 条 NIST 实验 IR 光谱用于 Demo 级可行性验证，未用于训练完整生成模型。

3. Demo 输入、运行与输出

输入

数据文件： 04_data/IR_nist_200.jsonl

每条记录包含：

字段	说明
smiles	分子 SMILES 字符串
value.x	波数数组 (cm^{-1})
value.y	归一化强度数组
source	数据来源 (NIST)

运行参数： query_id = 0, top_k = 5

查询分子按 query_id 从库中选取，其余 199 个分子构成候选库。

运行命令

```
# 运行 Demo
python 03_code/run_demo.py --query_id 0 --data 04_data/IR_nist_200.jsonl --top_k 5
```

```
# 运行测试
PYTHONPATH=03_code/src pytest 03_code/tests -q
```

输出文件

文件	说明
topk_candidates.csv	Top-K 候选排序表（含各指标得分）
spectrum_overlay.png	查询光谱与候选光谱叠加对比
molecule_grid.png	Top-K 候选分子结构
attention_heatmap.png	距离偏置注意力权重矩阵
ablation_results.csv	消融对比记录
trace_log.json	完整执行追踪日志

建议 reviewer 优先查看：

- 1. README.md —仓库总览
- 2. 02_demo_document/MultiSpec-GeoDiff_Demo_ 说明.pdf —本文档
- 3. 05_outputs/spectrum_overlay.png —谱图对比
- 4. 05_outputs/topk_candidates.csv —候选排序结果
- 5. 05_outputs/trace_log.json —执行记录

4. 输出示例展示

图 1：查询 IR 光谱（黑色）与 Top-K 候选光谱（彩色）叠加对比。用于展示候选分子是否在谱形上与查询样本保持一致。

图 2：Top-K 候选分子的二维结构。

图 3：谱图距离偏置注意力热图。对角线区域增强说明波数邻近区域具有更强的局部相关性，体现了横坐标物理先验的作用。




图 1: 谱图叠加对比




图 2: 候选分子结构




图 3: 注意力热图

5. 核心原理：为什么这个 Demo 能体现提案思路

5.1 谱图横坐标感知编码

$$h_i = W_I \cdot I_i + p(\nu_i)$$

IR 光谱的每个数据点不是无结构的序列 token，而是同时携带**强度信息** (I_i) 与**物理坐标** (ν_i , 波数)。嵌入层将强度投影 $W_I \cdot I_i$ 与傅里叶波数位置编码 $p(\nu_i)$ 相加，使模型天然地“知道”每个点位于光谱的哪个位置。

5.2 谱图距离偏置注意力

$$A_{ij} = \text{softmax}_j \left(\frac{Q_i K_j^T}{\sqrt{d}} + b(|\nu_i - \nu_j|) \right)$$

在普通 Transformer 中，token 间关系主要通过语义相似度建立。但在 IR 光谱中，**物理上邻近的波数区域具有更强的本征相关性**——这一先验不应由模型从有限数据中从头学习。本设计在注意力中注入波数间距依赖的 RBF 偏置 $b(\Delta\nu) = \exp(-(\Delta\nu/\sigma)^2)$ ，使得远离的谱区之间注意力权重被抑制。这与 Graph Transformer 中注入拓扑距离偏置的设计思路一致，但应用对象是**光谱物理坐标**而非图结构。

5.3 候选检索与前向谱图重排

$$\text{Score}(G_k) = \lambda_1 \text{CosSim}(S_q, S_k) + \lambda_2 \text{PeakMatch}(S_q, S_k) + \lambda_3 \text{L1Score}(S_q, S_k)$$

当前 Demo 使用**检索**而非训练完成的图扩散模型来产生候选——这是 Stage-I 的刻意设计。检索后，候选分子经前向谱图对比进行三指标重排，验证”候选提出 + 前向一致性校验”的闭环思想在真实实验 IR 数据上的可行性。这一闭环对应于完整提议中”生成模块负责提出候选，前向谱图模块负责物理校验”的核心理念。

6. 当前能力边界与诚实说明

已实现

- Stage-I 检索与重排闭环（200 条 NIST IR 光谱）

未作为训练模块实现

模块	当前状态	说明
图扩散生成器	未训练实现	当前用检索替代 de-novo 候选生成
Pairwise 距离预测器	接口桩	03_code/src/distance_head.py
TFN-Transformer	接口桩	03_code/src/tfn_transformer_stub.py
多模态谱图系统	未完整接入	当前仅 IR, Raman/NMR/MS/UV 等未接入
未知物鉴定基准	未完成	200 条数据仅支撑 Demo 级验证

这一边界是刻意的。 Demo 的目标是展示核心思路与可行性闭环，而非交付完整的生产系统。Stage-II 和 Stage-III 的关键模块已作为可导入接口桩存在于代码库中，定义了清晰的接口签名与数据结构，为后续开发提供了集成点。

7. 验证结果与可复现性

执行环境

项目	值
Python	3.10.18
PyTorch	2.8.0+cu126
RDKit	2025.03.6
平台	Linux (WSL2)

验证状态

项目	状态
本地 Demo 运行	通过
测试 (22 个)	全部通过
GitHub Actions CI	通过
输出文件	已提交至 05_outputs/
最新提交	main HEAD: 2bc955d (基线), 后续提交见仓库

消融实验说明

当前消融主要用于验证**流程各模块可被独立开关和记录**，而非证明统计显著的性能提升。Full pipeline 在纯余弦相似度之外引入了 L1 距离与峰匹配信号，使候选排序依据更接近谱图物理一致性，而非仅依赖向量空间相似度。

策略	Top-1 CosSim	额外排序信号
Baseline (原始余弦)	~0.97	无
Full (完整管线)	~0.97	+L1 + 峰匹配

重要提示： 由于样本规模仅 200，上述结果应理解为 **Demo 级可行性检验 (sanity check)**，不构成统计性能声明。在更大规模数据上的表现需要进一步验证。

8. 后续演进路线

Stage-II: 图扩散生成与 2D→3D 桥接

- 将当前检索式候选生成替换为**大小自适应图扩散模型**，实现 de-novo 分子图生成
- 增加 pairwise 距离预测: $G_{2D} \rightarrow D \rightarrow R^{(0)}$ ，以距离矩阵为二维拓扑到三维几何的桥梁

Stage-III: SE(3) 等变三维细化

- 引入 EGNN / TFN-Transformer，在三维空间中同步更新原子坐标与多阶张量特征
- 添加宇称分辨张量通道 (0e, 0o, 1e, 1o, 2e, 2o)，为 CD / VCD / ROA 等手性敏感模态预留接口

多模态扩展

- 从 IR 扩展至 IR / Raman / NMR / MS / UV / CD / VCD
- 实现跨模态注意力与多模态联合条件编码

9. 提交材料清单

材料	路径
GitHub 仓库	https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo
项目提议	01_project_proposal/proposal.md
Demo 说明 PDF	02_demo_document/MultiSpec-GeoDiff_Demo_说明.pdf
Demo 说明 Markdown	02_demo_document/demo_report.md
代码	03_code/ (核心模块 + 测试 + CLI 入口)
数据	04_data/IR_nist_200.jsonl (200 条 NIST IR 光谱)
输出	05_outputs/ (CSV, PNG, JSON)
Notebook	06_notebook/demo_pipeline.ipynb
CI	.github/workflows/tests.yml

主 命 令: `python 03_code/run_demo.py --query_id 0 --data 04_data/IR_nist_200.jsonl --top_k 5`
测试命令: `PYTHONPATH=03_code/src pytest 03_code/tests -q`