

## 目录

|                                     |          |
|-------------------------------------|----------|
| <b>1 MultiSpec-GeoDiff —Demo 说明</b> | <b>1</b> |
| 1.1 一、任务目标、定位与价值                    | 1        |
| 1.2 二、已完成的核心能力                      | 2        |
| 1.3 三、Demo 输入输出示例说明                 | 2        |
| 1.4 四、核心原理：Stage-I 最小闭环             | 4        |
| 1.5 五、当前 Demo 的能力边界                 | 6        |
| 1.6 六、验证结果与可复现性                     | 7        |
| 1.7 七、下一步可演进方向                      | 9        |
| 1.8 八、提交材料清单                        | 9        |

## 1 MultiSpec-GeoDiff —Demo 说明

DP Technology 实习最终提交 | 2026-05

GitHub 仓库: <https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo>

### 1.1 一、任务目标、定位与价值

本 Demo 对应提交的项目提议 “MultiSpec-GeoDiff: 多模态谱图驱动的几何分子结构反演” (详见 01\_project\_proposal/proposal.md)。

当前实现为 **Stage-I 可行性闭环**: 给定一张实验红外 (IR) 光谱, 系统通过坐标感知谱图编码、谱图距离偏置注意力、候选检索与前向谱图一致性重排, 从 200 个 NIST 实验光谱库中输出 Top-K 候选分子结构。

核心流程:

实验 IR 光谱 → 坐标感知谱图编码 → 候选检索 → 前向谱图重排 → Top-K 分子结构

本 Demo 的定位是**工作流可行性验证**, 而非训练完备的生成模型或生产级未知物鉴定系统。GitHub 仓库是主要提交入口。

## 1.2 二、已完成的核心能力

以下能力已在 Stage-I 中实现并可通过命令行复现：

| #  | 能力                      | 说明                                                     |
|----|-------------------------|--------------------------------------------------------|
| 1  | NIST 实验 IR JSONL 数据加载   | 200 条实验光谱，含 SMILES、波数、强度                               |
| 2  | 谱图插值与归一化                | 统一插值至 $400\text{--}4000\text{ cm}^{-1}$ ，1800 点公共网格    |
| 3  | 坐标感知谱图编码                | 强度投影 + 傅里叶波数位置编码                                       |
| 4  | 谱图距离偏置注意力               | 自注意力注入波数间距 RBF 偏置                                      |
| 5  | 候选分子检索                  | 全局嵌入池化 + 余弦相似度 Top-M 检索                                |
| 6  | 前向谱图一致性重排               | 余弦 + L1 + 峰匹配三指标加权重排                                   |
| 7  | Top-K 候选输出与可视化          | CSV 表格 + 谱图叠加 + 分子网格                                   |
| 8  | 注意力热图可视化                | 波数维度的注意力权重矩阵                                           |
| 9  | Trace log 生成            | 完整执行路径与元数据 JSON 记录                                     |
| 10 | 本地测试与 GitHub Actions CI | 22 个测试，CI 配置于 <code>.github/workflows/tests.yml</code> |

**关于数据规模：**当前使用 200 张 NIST 实验 IR 光谱进行 Demo 级可行性验证。这些数据未用于训练完整的生成模型，仅用于检索/重排闭环演示。

## 1.3 三、Demo 输入输出示例说明

### 1.3.1 输入

| 项目   | 内容                                           |
|------|----------------------------------------------|
| 数据文件 | 04_data/IR_nist_200.jsonl (200 条 NIST IR 光谱) |
| 查询参数 | <code>query_id = 0, top_k = 5</code>         |

查询分子从库中按 `query_id` 选取，其余 199 个分子构成候选库。

### 1.3.2 运行命令

# 运行 Demo

```
python 03_code/run_demo.py --query_id 0 --data 04_data/IR_nist_200.jsonl --top_k 5
```

# 运行测试

```
PYTHONPATH=03_code/src pytest 03_code/tests -q
```

### 1.3.3 输出文件

| 文件                               | 说明                       |
|----------------------------------|--------------------------|
| 05_outputs/topk_candidates.csv   | Top-K 候选分子排序表（含各指标得分）    |
| 05_outputs/spectrum_overlay.png  | 查询光谱与 Top-K 候选光谱叠加对比     |
| 05_outputs/molecule_grid.png     | Top-K 候选分子的二维结构图         |
| 05_outputs/attention_heatmap.png | 谱图距离偏置注意力权重热图            |
| 05_outputs/ablation_results.csv  | 消融对比结果（Baseline vs Full） |
| 05_outputs/trace_log.json        | 完整执行追踪日志                 |

### 1.3.4 输出示例图




图 1: 谱图叠加对比


图 1: 查询光谱 (黑色虚线) 与  $Top-K$  候选光谱 (彩色实线) 叠加对比

图 2: 候选分子结构

图 2:  $Top-K$  候选分子的二维结构图

图 3: 谱图距离偏置自注意力权重矩阵

## 1.4 四、核心原理：Stage-I 最小闭环

### 1.4.1 4.1 坐标感知谱图嵌入

与普通 Transformer 将输入视为无序 token 序列不同，IR 光谱的每个点同时携带**强度**与**波数物理坐标**。为此，嵌入层将强度投影与波数位置编码相加：

$$h_i = W_I \cdot I_i + p(\nu_i)$$

其中  $I_i$  为归一化强度， $p(\nu_i)$  为波数  $\nu_i$  的傅里叶位置编码， $W_I$  为可学习线性投影。




图 3: 注意力热图

### 1.4.2 4.2 谱图距离偏置注意力

普通 Transformer 的 token 关系主要是语义层面的。但在 IR 光谱中，**物理上邻近的波数区域具有更强的相互作用**，这一先验不应由模型从头学习。因此，自注意力注入波数间距依赖的偏置项：

$$A_{ij} = \text{softmax}_j \left( \frac{Q_i K_j^T}{\sqrt{d}} + b(|\nu_i - \nu_j|) \right)$$

其中  $b(\Delta\nu) = \exp(-(\Delta\nu/\sigma)^2)$  为 RBF 核，随波数间距增大而衰减，使得远离的谱区之间的注意力权重被物理先验抑制。

这一设计的本质与 Graph Transformer 中注入拓扑距离偏置类似，但应用对象从图结构变为**光谱坐标**。

### 1.4.3 4.3 检索与重排评分

候选分子经编码与池化后，与查询嵌入计算余弦相似度进行初筛（Top-M），随后通过前向谱图对比进行精细重排（Top-K）：

$$\text{Score}(G_k) = \lambda_1 \cdot \text{CosSim}(S_q, S_k) + \lambda_2 \cdot \text{PeakMatch}(S_q, S_k)$$

其中：-  $\text{CosSim}(\cdot, \cdot)$  为全谱向量余弦相似度 -  $\text{PeakMatch}(\cdot, \cdot)$  为谱峰位置与强度的匹配得分 -  $\lambda_1, \lambda_2$  为加权系数

这一前向谱图一致性校验的设计思路，对应完整提议中”生成模块提出候选，前向谱图模块物理校验”的闭环思想。

## 1.5 五、当前 Demo 的能力边界

### 1.5.1 已实现

- Stage-I 检索/重排可行性闭环（200 条 NIST IR 光谱）

### 1.5.2 未作为训练模块实现

| 模块                        | 说明                            |
|---------------------------|-------------------------------|
| 训练完成的图扩散生成器               | 候选生成当前使用检索替代，非 de-novo 生成     |
| 训练完成的 pairwise 距离预测器      | 距离预测头为接口桩                     |
| 训练完成的宇称分辨 TFN-Transformer | TFN 模块为接口桩                    |
| 完整多模态系统                   | 当前仅使用 IR, Raman/NMR/MS/UV 未接入 |
| 可靠的未知物鉴定基准                | 库规模与评估协议不足以支撑生产级鉴定            |

1.5.3 未来模块的代码桩

为保持架构完整性，Stage-II 和 Stage-III 的关键模块已作为可导入的接口桩存在于代码库中：

- 03\_code/src/distance\_head.py —2D 分子图 → pairwise 距离矩阵（Stage-II）
- 03\_code/src/tfn\_transformer\_stub.py —SE(3) 等变张量场细化（Stage-III）

这些文件定义了清晰的接口签名与数据结构，为后续开发提供了明确的集成点。

1.6 六、验证结果与可复现性

1.6.1 执行环境

| 项目      | 值            |
|---------|--------------|
| Python  | 3.10.18      |
| PyTorch | 2.8.0+cu126  |
| RDKit   | 2025.03.6    |
| NumPy   | 2.2.5        |
| SciPy   | 1.15.3       |
| 平台      | Linux (WSL2) |

1.6.2 验证结果

| 项目         | 状态   |
|------------|------|
| 本地 Demo 运行 | 成功   |
| 测试 (22 个)  | 全部通过 |

| 项目                | 状态               |
|-------------------|------------------|
| GitHub Actions CI | 通过               |
| trace_log.json    | 完整记录             |
| 输出文件              | 已提交至 05_outputs/ |

最新已知提交: main HEAD: 2bc955d

### 1.6.3 Trace Log 摘要 (05\_outputs/trace\_log.json)

| 字段    | 值                                                                                                                                 |
|-------|-----------------------------------------------------------------------------------------------------------------------------------|
| 光谱数量  | 200                                                                                                                               |
| 查询 ID | 5                                                                                                                                 |
| 查询分子  | C/C(=C/CCC1(C)C2CC3C(C2)C31C)COC(O)=Nc1cccc                                                                                       |
| Top-K | 3                                                                                                                                 |
| 已实现模块 | 8 个 (data_loader, spectra_preprocess, spectra_encoder, spectral_attention, candidate_generator, reranker, visualization, metrics) |

### 1.6.4 消融对比 (来自 05\_outputs/ablation\_results.csv)

| 策略                 | Top-1 CosSim | 说明                  |
|--------------------|--------------|---------------------|
| Baseline (原始余弦相似度) | ~0.97        | 无编码、无注意力            |
| Full (完整管线)        | ~0.97 + 重排   | 编码 + 距离偏置注意力 + 前向重排 |

消融显示 Full 管线在前向重排后提供了除纯余弦相似度之外的额外排序信号 (L1 距离、峰匹配), 使候选排序更具物理可解释性。



## 1.7 七、下一步可演进方向

1. **图扩散候选生成 (Stage-II)** — 将当前检索式候选生成替换为大小自适应图扩散模型，实现 de-novo 候选分子生成
2. **Pairwise 距离预测** —  $G_{2D} \rightarrow D \rightarrow R^{(0)}$ ，以距离矩阵为 2D 拓扑到 3D 几何的桥梁
3. **EGNN/TFN-Transformer 3D 细化 (Stage-III)** — 在三维空间中同时更新坐标与多阶张量特征
4. **多模态扩展** — 从单一 IR 扩展至 IR / Raman / NMR / MS / UV / CD / VCD
5. **手性敏感通道** — 若 CD/VCD/ROA 数据可用，引入 0o 宇称通道编码手性信息

## 1.8 八、提交材料清单

| # | 材料               | 路径/链接                                                                                                                                 |
|---|------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| 1 | <b>GitHub 仓库</b> | <a href="https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo">https://github.com/techandscixie2005/MultiSpec-GeoDiff-Demo</a> |
| 2 | 项目提议             | 01_project_proposal/proposal.md                                                                                                       |
| 3 | Demo 说明 PDF      | 02_demo_document/MultiSpec-GeoDiff_Demo_说明.pdf                                                                                        |
| 4 | Demo 说明 Markdown | 02_demo_document/demo_report.md (本文件)                                                                                                 |
| 5 | 代码               | 03_code/ (src + tests + run_demo.py)                                                                                                  |
| 6 | 数据               | 04_data/IR_nist_200.jsonl (200 条 NIST IR 光谱)                                                                                          |
| 7 | 输出               | 05_outputs/ (CSV, PNG, JSON)                                                                                                          |
| 8 | Notebook         | 06_notebook/demo_pipeline.ipynb                                                                                                       |
| 9 | CI               | .github/workflows/tests.yml (GitHub Actions, 已通过)                                                                                     |

主命令:

```
python 03_code/run_demo.py --query_id 0 --data 04_data/IR_nist_200.jsonl --top_k 5
```

测试命令:

```
PYTHONPATH=03_code/src pytest 03_code/tests -q
```